

Closed-form 2nd-order Data Shapley as a Spurious-Correlation Attenuator

Where it Works and Where it Doesn't
Anonymous Authors | ICLR 2026 Workshop | code: github.com/anon/fairds

+13.0 pp

OOD test_worst vs Vanilla
($p=5 \times 10^{-5}$, 10 seeds)

+4.7 pp

2nd-order isolation
(vs Fairds-1, $p=0.033$)

+55.3 pp

at strong spurious $p=0.99$
(phase transition, $p=3 \times 10^{-5}$)

1.89

Mann-Whitney p
(majority $\phi <$ minority ϕ)

Problem We Tackle

Spurious correlation 환경에서 ERM 은 majority 의 지름길 신호 (e.g. Colored MNIST 의 색) 를 잡아 minority / OOD worst-group accuracy 를 무너뜨린다.

표준 해법의 한계.

► Bi-level meta-learning (Ren 2018, FORML): minibatch 마다 inner SGD + implicit differentiation — 구현 무겁고 비용 큼.

► GroupDRO / IRM: **group label** 이 학습 중 필요.

► JTT: 2-stage ERM, 학습 동역학 으로의 개입은 없음.

Wang et al. 2024 는 *closed-form* 1차 / 2차 In-Run Shapley estimator 를 단일 학습 run 으로 유도 했다 — 그러나 **post-hoc filtering** (자-Shapley 샘플 제거 후 재학습) 에만 사용했다.

우리의 질문: 같은 closed-form 수식을 학습 중 *per-sample reweighter* 로 재용도 (repurpose) 할 수 있는가? 그리고 2차 cross-term 이 1차 단독 대비 **stand-alone** 기여를 주는가?

How We Approach It

핵심 아이디어 1 — 사후 필터링을 학습 중 가중치로.

Shapley 값을 학습이 끝난 뒤 사용하는 대신, 매 minibatch 마다 per-sample Shapley 추정치를 softmax 가중치로 환산해 가중 SGD 수행.

핵심 아이디어 2 — 2차 cross-term 의 기하학적 의미.

1차 항 $\langle g_i, g_{\text{val}} \rangle$ 은 단순 gradient alignment.

2차 cross-term $\langle g_i, H_{\text{val}} g_{\text{val}} \rangle$ 은 *validation loss* 의 곡률이 큰 방향에 *align* 된 *majority gradient* 에 추가 페널티 — curvature-aware down-weighting.

핵심 아이디어 3 — RMS rescaling.

학습 중 Hessian spectrum 이 수십 배 변동 — cross-term 을 그대로 더하면 발산. 매 step 1차 항의 RMS 에 맞춰 재스케일.

핵심 아이디어 4 — EMA 누적.

Per-step ϕ_i 는 noisy. iteration 간 EMA 로 평활화 후 softmax-weight.

► No implicit differentiation — 단일 forward + backward + HVP.

► Group label 은 anchor 50:50 균형에만 사용 (학습 중 불필요).

Method: Fairds — 5-Step In-Training Pipeline

파라미터 θ_t , minibatch $\mathcal{B}_t = \{z_i\}_{i=1}^B$, anchor $\mathcal{D}_{\text{val}}$ (50:50 group-balanced, $|\mathcal{D}_{\text{val}}|=200$). 매 step:

1 Per-sample gradient g_i .

$g_i = \nabla_{\theta} \mathcal{L}(z_i; \theta_t)$, `torch.func.vmap(grad)` 으로 단일 autograd graph 에서 한 번에.

2 Validation gradient & HVP.

$g_{\text{val}} = \nabla_{\theta} \mathcal{L}(\mathcal{D}_{\text{val}}; \theta_t)$, $H_{\text{val}} g_{\text{val}}$ via Pearlmutter HVP — full Hessian 불필요, $\mathcal{O}(P)$ 메모리.

3 Closed-form Shapley score.

$\phi_i^{(1)} = \langle g_i, g_{\text{val}} \rangle$ (1차)
 $\phi_i^{(2)} = \phi_i^{(1)} - \alpha \tilde{c}_i$, $c_i = \langle g_i, H_{\text{val}} g_{\text{val}} \rangle$ (2차)
 $\tilde{c}_i = c_i \cdot \frac{\text{RMS}_i(\phi^{(1)})}{\text{RMS}_i(c_i) + \epsilon}$ (RMS rescale)

4 EMA accumulate.

$\bar{\phi}_i \leftarrow \beta \bar{\phi}_i + (1 - \beta) \phi_i^{(2)}$, $\beta=0.9$.

Per-step ϕ 의 분산을 줄이고 minibatch boundary 효과 완화.

5 Softmax weight & weighted SGD.

$w_i = \text{clip}_{q_{0.05}, q_{0.95}} \left(\frac{B \cdot \exp(\bar{\phi}_i / \tau)}{\sum_j \exp(\bar{\phi}_j / \tau)} \right)$, $\theta_{t+1} = \theta_t - \eta \sum_i w_i g_i$.

알고리즘적 기여: cross-term 의 RMS rescaling — 빠지면 strong spurious bias 에서 Fairds-2 가 chance 까지 붕괴. ablation 으로 확인.

Hyperparameters

α 2차 weight = 1.0
 τ softmax temp = 0.5
 β EMA decay = 0.9
quantile clip [0.05, 0.95]
 $|\mathcal{D}_{\text{val}}|$ 200 (50:50)

Variants compared

Fairds-1: 식에서 $\alpha=0$ (1차만).

Fairds-2: $\alpha=1$ + RMS rescale.

두 variant 의 차이가 2차 *cross-term* 의 *isolated* 기여.

비용 (per step)

► g_i : vmap, 1 fwd + 1 bwd
► g_{val} : 1 fwd + 1 bwd
► HVP: 1 추가 bwd (Pearlmutter)
Wall-clock: vanilla 의 5–7× (small CNN).

Mechanism (E1b probe)

Controlled spurious-feature MLP, 8 input dim 중 2 dim 만 informative, spurious strength $s=10$.


► Mann-Whitney U ($\text{maj} < \text{min } \phi$):
 $p=1.89 \times 10^{-8}$ at imbalance ratio 0.9.

► $\Delta \phi$ ($\text{maj} - \text{min}$) 단조 감소: $0.50 \rightarrow +0.002$, $0.99 \rightarrow -0.025$.

Cross-term 이 H_{val} 의 dominant direction 과 align 된 majority gradient 에 페널티 — 메커니즘 직접 검증.


Phase Transition: Spurious Strength Sweep

$p_{\text{maj}} \in \{0.7, 0.8, 0.9, 0.95, 0.99\}$ sweep.




Colored MNIST (E3): Held-out OOD

10 seeds $\times$ 7 methods $\times$ 20 ep, best-tuned $\eta=0.05$.



Waterbirds (E3b): Regime Boundary

Pretrained ResNet-18 fine-tuning. 3 algorithmic variant 시도.



Takeaways

1. Closed-form 2nd-order Shapley reweighting 은 **regime-dependent** 도구다.

2. **From-scratch** / **spurious-correlation** 환경에서 작동 — 2차 cross-term 의 기여를 통계적으로 isolate 했다 (+4.7 pp, $p=0.033$).

3. **Pretrained fine-tuning** 환경에서는 실패 — bi-level meta-learning 이 더 강하다 (정직 보고).

4. Cross-term 의 RMS rescaling 이 안정성의 키 (없으면 발산).

Vanilla

Fairds-1

Fairds-2

Ren2018

Held-out OOD test_worst 7 methods